西安交通大学

# 仓颉语言程序设计

# 项 目 开 题 报 告

项目名称：仓颉程序诊断与测试验证工具

项 目 组 长：张宇宸

项 目 成 员：石澄錡、高远

**西安交通大学《仓颉语言程序设计》课程组**

**2026 年 9 月制**

# 一、选题的理论意义与实际意义

本项目拟实现“仓颉程序诊断与测试验证工具”（Cangjie Code Doctor），用探索性 A/B 对照回答“加入同版本官方文档检索，课程程序的修复成功率是否变化”。工具承载实验与证据留存，三人按八个开发周推进。

## 1 选题背景与使用场景

学生在课程练习中遇到类型不匹配、变量未定义或函数参数错误时，往往能看到报错，却不清楚错误为什么产生、涉及哪个知识点、应该改哪里。直接询问通用模型虽然方便，但模型可能使用不适配当前 SDK 的接口，或在消除编译错误的同时改变原有逻辑。

本工具提供一个本地 Web 界面：学生粘贴或打开源码，点击诊断查看错误位置和原始消息；需要帮助时请求中文解释及文档依据，核对代码差异后决定是否应用到副本；随后输入测试样例，查看预期与实际输出。界面保留原始版本和修改记录，使学生能解释修改原因并复查结果。

## 2 理论与技术意义

课题研究编译诊断、文档检索、模型修改与测试反馈的协同应用。仓颉实现核心流程并统一实验条件，支持逐案例对照。技术贡献在于流程实现与证据组织，不预设检索有效，不将方法组合表述为首创。

两组固定模型、参数、轮次和反馈规则，仅改变是否提供同版本文档。案例集预先冻结，保留测试不泄露。定位、确认、回退和报告单独验收，确保工具稳定可用；试用意见不替代修复结果证据。

## 3 实际意义与结果边界

学生主导修改并核对文档依据、测试及历史记录；未配置模型时仍可手工诊断和验证。本组聚焦修复流程及受控评估，第三组聚焦知识点、练习推荐与教师统计，双方可在任务和样本上协作。

编译错误以编译器消息为依据；运行错误依据异常、退出状态和日志分析；逻辑错误必须结合题意、预期输出及失败测试讨论。没有有效测试时标记“行为未验证”。编译成功与测试通过分别展示，测试通过只表示满足当前样例，不证明对所有输入均正确。

项目实现覆盖文件处理、集合、结构化数据、异常处理、进程管理、HTTP 通信和模块协作。通过完成诊断、交互与验证模块，形成可运行软件、可复查记录及明确的个人贡献，体现仓颉课程的工程实践要求。

# 二、国内外有关选题的研究动态

## 1 检索增强与程序修复研究

Lewis 等提出检索增强生成方法，将外部知识引入生成任务[1]。本项目借鉴这一思路，检索固定版本的仓颉官方文档作为解释依据，首版采用关键词与 BM25 排序，不复现论文中的训练结构。Xia 和 Zhang 的对话式程序修复结合候选代码与验证反馈[2]，为有限轮次修改和逐轮记录提供参考。

Liang 等的 Java 到仓颉翻译预印本结合多阶段模型训练、编译反馈与错误修复案例检索[3]，表明仓颉领域已有相关研究。本项目采用既有模型，侧重单文件课程程序的交互诊断和测试验证，不进行代码翻译或模型训练，也不把“检索加反馈”称为首创。

## 2 仓颉工具基础与项目定位

官方 cjc 文档说明了 --diagnostic-format=json 诊断输出选项[4]，可作为错误结构化的技术基础；具体字段、位置格式和异常行为须在选定 SDK 中验证。CangjieMagic 提供模型接入与检索增强等能力[5]，可作为参考或可选依赖。首周验证兼容性，若只需单一模型接口，优先评估仓颉 HTTP 客户端直接接入的工作量。

本项目把诊断定位、解释依据、修改确认、回退和测试报告组织成稳定流程，并通过受控 A/B 回答检索是否改变修复结果。实验与工具相互支撑：工具提供一致执行与记录，实验约束效果结论。相关研究结果不能直接充当本项目成绩，学生试用也不能替代案例对照。

## 3 主要参考资料

[1] Lewis P, et al. Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks[C]. NeurIPS, 2020. https://arxiv.org/abs/2005.11401

[2] Xia C S, Zhang L. Conversational Automated Program Repair[EB/OL]. 2023. https://arxiv.org/abs/2301.13246

[3] Liang X, Zhang J, Li L, et al. Boosting Automatic Java-to-Cangjie Translation with Multi-Stage LLM Training and Error Repair[EB/OL]. 2026. https://arxiv.org/abs/2605.07403

[4] 仓颉编程语言官方文档. cjc 编译选项（1.0.0）[EB/OL]. https://docs.cangjie-lang.cn/docs/1.0.0/user_manual/source_zh_cn/Appendix/compile_options.html

[5] Cangjie-TPC. CangjieMagic 项目文档[EB/OL]. https://gitcode.com/Cangjie-TPC/CangjieMagic

在线资料核对日期：2026 年 10 月 9 日。开发时固定 SDK、依赖、文档快照和模型标识，并记录版本清单；引用的文档版本不自动等同于最终开发版本。

# 三、研究内容（项目模块）

### 1 首版范围与用户流程

首版支持固定 SDK 下、不超过 200 行、仅使用标准库的 .cj 单文件练习，采用确定性的标准输入输出测试。暂以一套固定 Linux 容器环境作为部署与验收基线，第一周验证后锁定版本及资源参数；不承担多平台隔离适配、多文件工程、完整 IDE 或自动生成验收答案。

本地 Web 界面与可复查的批量实验入口均为必交付。交互流程为导入源码、编译诊断、请求解释、核对差异、确认副本、测试和报告；实验入口按固定协议运行同一核心流程。关闭 AI 仍可手工修改与验证。缺少题意或有效测试时只解释已知现象，不宣称逻辑已修复。

### 2 代码输入与交互界面

界面采用源码区、诊断解释区和验证结果区，提供行号及错误定位、题意输入、测试输入与预期输出编辑。源码支持基本编辑即可，不实现完整补全或调试器。诊断、请求解释、确认修改、运行测试分别操作，显示处理中、成功、失败、取消和未验证状态，避免重复提交。

导入后保存原始快照，编辑只作用于任务副本。已有诊断或建议绑定源码摘要；用户再次编辑时，旧结果标记过期，重新诊断后才能应用对应建议。首页提供 3 个经审核的典型错误示例，覆盖类型不匹配、变量未定义和参数错误，示例从开发集选取，便于第一次体验与课堂演示。

### 3 编译诊断与中文解释

以固定命令和参数列表调用 cjc，优先读取 JSON 诊断，记录退出码、原始日志、文件位置、严重程度、消息及耗时。第一个版本即能点击错误定位源码；字段缺失或解析不完整时保留原文并提示，不把空诊断列表解释为编译通过。编译器退出状态与消息共同构成结果依据。

启用 AI 后，将当前代码、诊断和适用文档片段组织为请求，要求返回中文错误含义、结合源码的原因、可选修改方案及知识点依据。原始报错保留可查看，推断性解释明确标为模型建议。先修正一个问题可能消除后续连带报错，因此界面允许重新诊断，不保证逐条报错都对应独立原因。

### 4 文档检索与依据展示

对固定版本官方文档按章节和示例分段，保存编号、标题、来源及 SDK 版本。使用诊断关键词、标识符与 BM25 排序返回少量片段，参数只在开发案例上调整。引用只能指向实际检索到的片段，点击可查看原文；无匹配时明确显示缺少文档依据，不生成虚假链接。解释是否正确仍需人工和后续验证检查。

## 5 差异确认与测试验证

模型返回修改说明、完整候选代码和引用编号，工具校验字段、长度和引用后计算差异。用户可接受、拒绝或手工修改候选；接受后写入独立副本，不覆盖导入文件。用户确认只是允许应用本次修改，不能替代运行环境隔离。模型不得修改题意、测试预期值或输出比较规则。

候选在受限环境中重新编译，通过后逐项运行用户提供的测试。结果同时展示输入、预期输出、实际输出、退出状态及耗时，区分输出不符、异常退出、超时、输出超限和未执行。默认精确比较 UTF-8 输出；换行处理或浮点容差仅按预先声明的规则执行。没有有效测试时显示“行为未验证”。

修复流程最多生成两轮建议。首轮未通过公开测试时，用户可请求结合本轮编译或测试反馈再尝试；第二轮仍须确认。公开测试通过、用户取消、无有效变化或预算耗尽时停止。原始程序已通过当前测试时，默认展示结果，不自动要求模型改写；这也不代表已经发现或排除所有逻辑错误。

## 6 诊断历史与报告

每个任务保存原始源码、各轮候选、人工修改、文档依据及验证结果。用户可以恢复任务中的历史副本；回退后保留旧记录，新的测试结果重新生成。首版采用本地文件存储，不开发账号、云同步或多人协作。

导出 JSON 和本地 HTML，保存源码与配置摘要、两组标识、逐轮输入输出、检索依据、差异、测试及终止原因。报告可由原始记录重新汇总，失败同样留档。内容转义并去除密钥与个人路径；公开报告不包含尚未解封的保留测试。

## 7 架构与接口协作

仓颉核心服务负责任务、诊断、检索、模型调用、验证调度和报告；轻量 HTML/JavaScript 页面承担编辑与展示，可按熟悉程度采用 Vue。核心业务不迁移到前端，本地服务仅监听回环地址，静态资源随程序提供。第一周核对课程对前端依赖的要求，第二周即打通界面与编译接口。

共享数据包括任务与源码摘要、编译诊断、文档证据、修改建议及逐项测试报告，统一携带任务编号、源码版本和轮次。编译状态与测试状态分别存储，未执行、取消和工具故障不能映射为通过。前端仅对返回数据展示和提交操作，不自行判断“修复成功”。

模型接口采用适配层，首版只接入一个服务。用户启用 AI 时说明发送的源码与诊断范围，密钥留在协调服务且不进入执行容器。网络中断、无效响应或超出调用上限时保存任务并提示，仍允许手动修改和验证。CangjieMagic 兼容性不足时改用仓颉 HTTP 客户端，不另做智能体规划或向量数据库。

## 8 探索性 A/B 实验设计

拟准备 30 个案例，10 个用于开发，20 个用于评估。评估集含 16 个错误案例：语法、类型、作用域或接口误用各 4 个，另有 4 个可编译逻辑错误；4 个正确案例单列做回归检查。按原题与同源变体整体划分，记录来源、题意、SDK 和文件摘要，两名成员交叉核验参考行为。

每个错误须由编译诊断或公开测试暴露。公开测试用于修复，保留测试独立覆盖正常与边界行为，不进入模型、检索、人工候选选择或公开仓库。第六周冻结数据、文档快照、提示、检索参数、比较规则、代码版本与判定流程；保留测试由独立入口在全部候选锁定后读取。

A 组输入题意、源码、公开测试及原始编译和测试结果；B 组仅额外加入同版本文档片段。两组均最多两轮，失败后接收各自上一候选的编译与公开测试反馈。B 组按初始诊断检索并固定片段供两轮复用。模型标识、采样参数、输出上限、提示骨架、环境、停止与候选规则一致，检索开关为唯一有意改变的因素。

每个错误每组运行一次，计划最多 16×2×2＝64 次生成；故障重跑另计成本。预先固定案例与组别顺序，在相近时间配对执行，记录实际用量、费用和耗时。交互模式允许用户编辑；主实验不加入人工改写或补充提示，候选按协议自动确认进入隔离验证，二者结果分开记录。

首轮编译且公开测试全过即停止并保留该候选，否则最多进入第二轮，最后采用最近一轮格式有效、含候选代码的响应；没有有效候选记失败。取消、无变化或预算耗尽依预定规则终止。非法响应和接口失败不选择性重试或删除，若服务故障需重跑，则按事先规则对受影响配对统一重跑并保留旧记录。

修复成功定义为最终候选编译成功且通过全部公开和保留测试。主指标分别报告两组成功数 / 16 及差值；逐案例列出“两组均成功、仅 A 成功、仅 B 成功、两组均失败”，差值为（仅 B 成功数－仅 A 成功数）/ 16。编译恢复率仅针对初始编译失败的 12 例，逻辑错误 4 例另报。正确回归案例不混入修复率。

记录首轮与最终结果、错误类型和成本，人工复核可疑硬编码、删减功能及输入约定变化。第二轮变化只作描述，不单独归因为反馈。由原始记录重新汇总应得到相同计数，但在线模型重调不保证同一输出。本轮规模只支持探索性或先导性结论，不据单次比例差宣称统计显著或普遍优势。

## 9 不同结果的呈现与解释

在实验前固定结果表和分析顺序，完整报告 A、B 的成功数量、配对四种结果、错误类型、耗时和成本。若 B 优于 A，仅说明本配置和案例集观察到改善；若结果接近，表述为“本次未观察到明确优势”；若 B 较差，如实报告下降，不将负面案例从主结果剔除。未实施预定统计检验时，不使用统计显著性结论。

无明显提升或下降时，检查检索是否相关、文档是否适配、错误是否本已容易修复、上下文是否引入干扰，并结合具体输入输出解释。上述原因属于待证实分析，不以推测替代证据。功能验收与试用另行报告，既不能替代 A/B，也不能因检索未提高成功率而否认已验证的流程能力。

结论范围限定为所选模型、版本、运行环境及案例集。单次生成和小样本均是限制；检索无明显优势不证明其普遍无效，也不能反称已经有效。答辩以实验协议、实际记录和失败案例展示工作，而不预设正面结果。

## 10 工具可用性验收

登记 10 个端到端任务，检查定位、解释、确认或拒绝、回退、测试与报告，覆盖编译错误、运行异常、逻辑失败、正确程序和无测试情形。验证编译器不可用、诊断不完整、检索为空、非法响应、断网、超时及输出超限。拒绝或取消后原文件摘要不变，旧结果与源码版本对应，失败状态不能显示为通过。

拟邀请 3—5 名非项目成员完成操作任务，记录完成情况和困难；预先指定 10 个错误评估案例，交叉复核解释、建议及引用，无效或缺失解释计入失败。试用用于确认工具可操作，不评价长期教学效果，不代替受控修复实验。

## 11 与第三组的定位及合作

第三组“仓颉程序学习助手”以错误关联知识点、练习推荐和教师统计构成学习流程。本组以诊断修复为对象，用受控对照回答文档检索是否改变修复成功率。定位说明写清核心问题、流程和证明方式，允许文档检索、中文解释等基础能力交叉，不设置排他性功能边界。

双方可讨论题库调用诊断、共同试用或提供真实错误样本，具体安排尚待协商。样本须获授权、去标识并核验题意、参考实现及测试；冻结前按同源规则纳入，冻结后单列扩展集。不得根据主实验结果筛选有利样本、修改原分母或泄露保留测试。

### 12 可行性与风险控制

第一周验证 SDK、JSON 诊断、HTTPS、模型格式与容器限制，锁定一套环境。编译和运行复用现成隔离设施，限制网络、可写目录、时间、内存及输出；超时终止任务及其子进程，不挂载用户主目录或密钥。

独立目录与用户确认不能替代隔离。限制未通过实测时，关闭任意候选的自动编译运行，仅对逐份人工审核的课程样例受控演示，并记录未完成项。诊断、引用或响应无法确认时保留原始信息和异常状态。

第二周联调界面并起草实验协议，第四周贯通修改验证，第六周冻结。进度风险优先通过缩减扩展功能、界面美化及额外重复实验处理，保留核心交互、A/B 条件控制、测试隔离与完整记录，避免以工具展示替代实验。

### 13 预期成果

交付诊断助手、仓颉源码、部署说明、文档索引、冻结案例及实验协议、原始记录、配对结果和失败分析。演示兼顾定位、确认、回退与报告，展示两组证据及结论边界。材料中的效果数值均待实测后填写。

## 四、人员及分工

张宇宸任组长，石澄錡、高远为成员。每人承担模块实现、测试与文档，共同完成案例及解释复核。

| 成员 | 主要职责 | 可检查交付物 |
| --- | --- | --- |
| 张宇宸<br>组长 | 统筹架构与集成；文档索引、BM25、模型与候选校验；制定 A/B 协议和预算。 | 检索与修复模块、提示版本、实验配置及协议。 |
| 石澄錡 | 编译诊断、测试及隔离；复核参考行为，维护独立保留测试和判定规则。 | 验证模块、运行环境、测试依据及判定记录。 |
| 高远 | 任务与历史、本地 Web、定位与差异、回退和报告；批量调度与配对汇总。 | 可操作界面、原始记录、批量入口及结果表。 |

第二周固定接口与协议草案，第六周冻结案例、配置和工具版本。三人交叉复核案例与解释，并分担原始记录审计。每周检查可运行提交，合并前复核接口和测试，记录复用范围与个人贡献。

AtomGit 为主仓库，GitHub 保留同步副本。主仓库地址：
https://gitcode.com/A72316/cangjie-code-doctor

## 五、项目进度安排（具体到周）

按八个开发周推进，具体日期依课程节点登记。工具实现、案例整理和协议设计同步进行，第六周冻结，第七周运行受控 A/B，第八周交付可复查证据及探索性结论。下表为计划，不代表各阶段已经完成。

| 周次 | 主要工作 | 周末检查成果 |
| --- | --- | --- |
| 第 1 周 | 确认研究问题和范围；验证 SDK、诊断、模型与隔离；估算预算，梳理第三组的定位与合作机会。 | 环境清单、研究问题、交互原型。 |
| 第 2 周 | 固定接口并接入界面定位；准备 10 个开发案例；起草对照协议及案例规范，讨论真实样本来源。 | 基础界面、开发案例、协议草案。 |
| 第 3 周 | 实现文档检索和中文解释；校验引用；统一 A/B 输入、反馈与日志结构。 | 解释与文档依据、两组配置样例。 |
| 第 4 周 | 完成差异确认、测试比对、取消与原文件保护；核对隔离限制；贯通批量记录。 | 交互单轮流程、可追溯运行记录。 |
| 第 5 周 | 完成两轮流程、回退、报告和配对汇总；复核 30 个计划案例，纳入已获授权的适用真实样本。 | 完整工具、复核案例、结果表模板。 |
| 第 6 周 | 完成功能与异常检查；冻结 10 / 20 划分、文档、模型参数、协议和代码版本；隔离保留测试。 | 冻结清单、稳定版本、独立测试入口。 |
| 第 7 周 | 按协议运行两组，锁定候选后解封测试；核对配对结果与成本，分析全部结果并开展学生试用。 | 原始记录、配对表、失败及试用分析。 |
| 第 8 周 | 复测修复项并记录影响；完成正负结果解释、局限、复现说明和答辩，明确后续扩展方向。 | 最终软件、证据材料和探索性结论。 |

第四周检查核心流程，第六周完成冻结，第八周交付。模型不可用时可回放明确标记的历史记录，不能计为新实测。评估后若修复影响结果的缺陷，记录版本并对受影响的两组统一重跑。真实样本在冻结前纳入；冻结后新增样本另建扩展集，不据主实验结果改变原分母。